پیش‌بینی تصادف در ویدیوهای دش‌کم با مدل MViT V2-S

انتقال یادگیری (Transfer Learning) مبتنی بر ترنسفورمرهای بینایی چندمقیاسه روی دیتاست Nexar

۱. معرفی مسئله و هدف پروژه

هدف این پروژه، تخمین احتمال وقوع تصادف در ویدیوهای ثبت‌شده توسط دوربین خودرو (Dashcam) در رقابت Nexar است. در این رویکرد، از معماری ترنسفورمر ویدیویی پیش‌آموزش‌دیده **MViT V2-S (Multiscale Vision Transformer v2 - Small)** استفاده شده است تا الگوهای مکانی-زمانی (Spatiotemporal) منتهی به تصادف در سه افق زمانی پیش‌بینی (۰.۵، ۱.۰ و ۱.۵ ثانیه قبل از حادثه) شناسایی شوند.

۲. مشخصات دیتاست و پیش‌پردازش متادیتا

مجموعه‌داده شامل ویدیوهای آموزشی و تست با فرمت MP4 است. در گام نخست، شناسه‌های ویدیوها به رشته‌های ۵ رقمی با صفرهای ابتدایی (Leading Zeros) نرمال‌سازی شده و متادیتای دقیق هر ویدیو شامل نرخ فریم و طول زمانی استخراج گردیده است:

بخش داده (Split)	تعداد ویدیوها	توزیع برچسب‌ها	میانه طول ویدیوها (ثانیه)
آموزش (Train)	1,500	۷۵۰ مثبت (تصادف) / ۷۵۰ منفی (عادی)	40.131 s
تست (Test)	1,344	برچسب پنهان (ارزیابی رقابت)	9.960 s

۳. استراتژی افراز داده و ساخت کلیپ‌های زمانی

برای جلوگیری از نشت اطلاعات (Data Leakage)، افراز داده‌ها در **سطح ویدیو (Video-Level Split)** به نسبت ۸۰٪ آموزش (۱,۲۰۰ ویدیو) و ۲۰٪ اعتبارسنجی (۳۰۰ ویدیو) به صورت Stratified انجام شده است. کلیپ‌های زمانی تا سقف ۱۰ ثانیه در افق‌های زمانی **(0.5s, 1.0s, 1.5s)** ساخته می‌شوند:

- **ویدیوهای مثبت (دارای تصادف):** کلیپ‌ها دقیقاً به اندازه افق زمانی **h** قبل از زمان وقوع تصادف (time_of_event - h) پایان می‌یابند. برای افق‌های بزرگتر از ۰.۵ ثانیه، تنها کلیپ‌هایی انتخاب می‌شوند که فاصله زمانی هشدار تا تصادف (lead_time = time_of_event - time_of_alert) بزرگتر از افق **h** باشد.
- **ویدیوهای منفی (بدون تصادف):** از آنجا که ویدیوهای منفی فاقد زمان رویداد و هشدار هستند، توزیع فاصله رویداد از وسط ویدیو و توزیع زمان هشدار صرفاً از روی ویدیوهای مثبت بخش آموزش تخمین زده شده و برای نمونه‌برداری مصنوعی (Synthetic Timestamps) کلیپ‌های منفی با همان قوانین فیلترینگ به کار می‌رود.

افق زمانی (Horizon)	آموزش: کلاس ۰	آموزش: کلاس ۱	اعتبارسنجی: کلاس ۰	اعتبارسنجی: کلاس ۱
0.5 ثانیه	600	600	150	150
1.0 ثانیه	454	452	110	104
1.5 ثانیه	281	280	76	67
مجموع کل کلیپ‌ها	کلیپ (از 1,200 ویدیو) 2,667		کلیپ (از 300 ویدیو) 657	

۴. خط لوله پردازش فریم و معماری مدل MViT V2-S

از هر کلیپ زمانی، ۱۶ **فریم** به صورت یکنواخت (Uniform Sampling) استخراج شده، به فضای رنگی RGB تبدیل و به ابعاد **224 × 224** تغییر اندازه داده می‌شوند. سپس با میانگین **[0.432, 0.395, 0.376]** و انحراف معیار **[0.228, 0.221, 0.217]** دیتاست Kinetics-400 نرمال‌سازی می‌گردند. ابعاد تانسور ورودی هر بچ به صورت **(2, 3, 16, 224, 224)** است.

در استراتژی انتقال یادگیری (Fine-Tuning)، وزن‌های اولیه از Kinetics-400 بارگذاری شده و لایه خروجی با یک لایه خطی ۲ کلاسه جایگزین گردیده است. برای جلوگیری از بیش‌برازش و کاهش بار محاسباتی، تنها **آخرین بلوک ترنسفورمر (blocks[-1])**، **لایه نرمال‌سازی (norm)** و **سر طبقه‌بند (head)** آموزش می‌بینند:

پارامتر معماری و آموزش	مقدار / تنظیمات	جزئیات فنی
تعداد کل پارامترهای مدل	34,231,682	معماری استاندارد MViT V2-S
پارامترهای قابل آموزش (Trainable)	7,103,234 (20.75%)	فقط بلوک آخر، لایه Norm و Head
پارامترهای فریز شده (Frozen)	27,128,448 (79.25%)	بلوک‌های استخراج ویژگی اولیه و میانی
بهینه‌ساز و تابع زیان	AdamW / CrossEntropyLoss	نرخ یادگیری 1e-5 برای بلوک/نرمال‌ساز و 1e-4 برای Head؛ WD=1e-4
سخت‌افزار و تنظیمات اجرا	2 × NVIDIA Tesla T4	استفاده از nn.DataParallel، اندازه بچ ۲، طی ۳ ایپاک

۵. نتایج آموزش و ارزیابی روی داده اعتبارسنجی

معیار اصلی ارزیابی مدل، میانگین دقت متوسط (**mAP - Mean Average Precision**) در سه افق زمانی است. روند بهبود یکنواخت مدل در طول ۳ ایپاک آموزش به شرح زیر ثبت شده است:

ایپاک (Epoch)	زیان آموزش (Train Loss)	زیان اعتبارسنجی (Val Loss)	AP افق 0.5s	AP افق 1.0s	AP افق 1.5s	میانگین AP (mAP)
Epoch 1 / 3	0.6758	0.6561	0.7040	0.6787	0.6399	0.6742
Epoch 2 / 3	0.6360	0.6276	0.7115	0.6894	0.6472	0.6827
Epoch 3 / 3 (Best)	0.6059	0.6256	0.7232	0.6911	0.6737	0.6960

جدول کامل عملکرد بهترین چک‌پوینت (ایپاک سوم) به تفکیک افق زمانی

افق پیش‌بینی (Horizon)	دقت متوسط (AP)	سطح زیر نمودار (ROC-AUC)	خط پایه تصادفی (Baseline AP)	بهبود نسبت به خط پایه
ثانیه قبل از تصادف 0.5	0.7232	0.7180	0.5000	+0.2232 (+44.6%)
ثانیه قبل از تصادف 1.0	0.6911	0.7182	0.4860	+0.2051 (+42.2%)

افق پیش‌بینی (Horizon)	دقت متوسط (AP)	سطح زیر نمودار (ROC-AUC)	خط پایه تصادفی (Baseline AP)	بهبود نسبت به خط پایه
ثانیه قبل از تصادف `1.5`	`0.6737`	`0.7256`	`0.4685`	`+0.2052 (+43.8%)`

۶. استنتاج روی داده تست (Test Inference) و تولید خروجی نهایی

در مرحله تست، برای پوشش کامل بازه‌های زمانی هر ویدیو، از هر ویدیوی تست **۳ کلیپ تا طول ۱۰ ثانیه** در فواصل زمانی یکنواخت استخراج شد (در مجموع `1,344 × 3 = 4,032` کلیپ تست در ۲,۰۱۶ بچ). احتمال تصادف برای هر کلیپ با تابع Softmax محاسبه گردید که مقادیر آن در بازه `[0.1421, 0.9457]` قرار داشت.

تجمیع نهایی (Max-Pooling Aggregation) و جمع‌بندی: برای تعیین امتیاز نهایی هر ویدیو در فایل `submission.csv`، بیشینه احتمال (Max Score) در میان ۳ کلیپ استخراج‌شده به عنوان احتمال وقوع تصادف آن ویدیو انتخاب شد. مدل MViT V2-S با دستیابی به `mAP = 0.6960` عملکرد بسیار قدرتمند و پایداری در درک مستقیم روابط مکانی-زمانی فریم‌ها از خود نشان می‌دهد.