پیش‌بینی تصادف دش‌کم با معماری ResNet18 و شبکه Bi-GRU

استخراج ویژگی‌های مکانی فریم‌ها و مدل‌سازی دنباله زمانی با مکانیزم توجه (Temporal Attention)

۱. معرفی معماری و نوآوری خط لوله (Pipeline)

در این رویکرد، یک طبقه‌بند زمانی دو مرحله‌ای برای مسأله پیش‌بینی تصادف Nexar طراحی شده است. ابتدا یک شبکه کانولوشنی پیش‌آموزش‌دیده **ResNet18** بردار ویژگی ۵۱۲ بعدی را از هر فریم استخراج و در حافظه ذخیره (Cache) می‌کند. سپس یک شبکه بازگشتی **GRU دوطرفه (Bidirectional GRU)** به همراه **لایه توجه زمانی (Temporal Attention)** دنباله مرتب ویژگی‌ها را پردازش می‌کند تا لحظات کلیدی شروع خطر را وزن‌دهی و شناسایی نماید.

۲. تحلیل متادیتا و ساخت کلیپ‌های زمانی بدون فیلتر حذفی

دیتاست شامل ۱,۵۰۰ ویدیوی آموزشی (طول ۱۴ تا ۶۰ ثانیه، میانه ۴۰.۱۳ ثانیه) و ۱,۳۴۴ ویدیوی تست (طول ۶.۵۶ تا ۱۱.۳۳ ثانیه، میانه ۹.۹۶ ثانیه) است. افراز داده در سطح ویدیو به صورت ۸۰٪ آموزش (۱,۲۰۰ ویدیو) و ۲۰٪ اعتبارسنجی (۳۰۰ ویدیو) انجام شده است. برخلاف رویکرد اول، در این نوت‌بوک **برای تمام ویدیوها در هر ۳ افق زمانی (۰.۵، ۱.۰ و ۱.۵ ثانیه) کلیپ ۱۰ ثانیه‌ای ساخته می‌شود** (بدون حذف هیچ کلیپی):

- **برچسب‌گذاری دقیق زمانی در ویدیوهای مثبت:** کلیپ در زمان `event_time - horizon` پایان می‌یابد، اما برچسب آن تنها زمانی ۱ (مثبت) می‌شود که زمان هشدار تا آن لحظه فرا رسیده باشد (`event_time - alert_time >= horizon`)؛ در غیر این صورت برچسب آن کلیپ ۰ منظور می‌گردد.
- **تخمین موقعیت کلیپ‌های منفی:** آفست زمانی وقوع حادثه نسبت به وسط ویدیو روی داده‌های مثبت آموزش (با حذف ۲٪ داده‌های پرت بالا و پایین) دارای میانگین `-0.0944` و انحراف معیار `0.9086` ثانیه است که برای نمونه‌برداری موقعیت کلیپ‌های منفی استفاده می‌شود.

افق زمانی (Horizon)	آموزش: برچسب ۰	آموزش: برچسب ۱	اعتبارسنجی: برچسب ۰	اعتبارسنجی: برچسب ۱
`0.5` ثانیه	`638`	`562`	`159`	`141`
`1.0` ثانیه	`743`	`457`	`196`	`104`
`1.5` ثانیه	`915`	`285`	`232`	`68`
مجموع کل کلیپ‌ها	`3,600` (از `1,200` ویدیو) کلیپ		`900` (از `300` ویدیو) کلیپ	

۳. استخراج و ذخیره‌سازی ویژگی‌های فریم با ResNet18

از هر کلیپ، **۲۴ فریم** با فواصل زمانی یکنواخت نمونه‌برداری شده و با حفظ نسبت تصویر ۱۶:۹ اصلی ویدیوها، به ابعاد `224 × 128` تغییر اندازه می‌یابند. برای بهینه‌سازی مصرف رم، فریم‌ها به صورت تانسور `uint8` بارگذاری شده و روی GPU نرمال‌سازی می‌شوند. در بخش آموزش، افزایش داده (Augmentation) شامل تغییر روشنایی و کنتراست در بازه `[0.90, 1.10]` به صورت یکپارچه روی کل کلیپ اعمال می‌گردد. خروجی استخراج ویژگی با دقت نیمه‌اعشاری (`float16 autocast`) به صورت تانسورهای `(3600, 24, 512)` برای آموزش و `(900, 24, 512)` برای اعتبارسنجی روی دیسک ذخیره می‌شود.

۴. معماری مدل TemporalGRUClassifier و تنظیمات آموزش

به لطف کش کردن ویژگی‌ها، آموزش شبکه بازگشتی بسیار سریع انجام می‌شود (هر اپیاک کمتر از ۱ ثانیه). جزئیات معماری و ابرپارامترهای کنترلی بیش‌برازش در جدول زیر آمده است:

بخش معماری / آموزش	مشخصات فنی	توضیحات و نقش در مدل
لایه بازگشتی (Bi-GRU)	`Input: 512 | Hidden: 256 | 2 Layers`	دوطرفه (خروجی ۵۱۲ بعدی در هر گام زمانی) با `Dropout = 0.30`
مکانیزم توجه (Attention)	`Linear(512→128) + Tanh + Linear(128→1)`	محاسبه وزن اهمیت هر یک از ۲۴ فریم با Softmax و جمع وزن‌دار
سر طبقه‌بند (Classifier)	`LayerNorm(512) → Linear(512→128) → Linear(1)`	همراه با ReLU و لایه‌های Dropout با نرخ‌های `0.30` و `0.225`
تعداد پارامترهای قابل آموزش	`2,498,050` پارامتر	آموزش کامل شبکه GRU، لایه Attention و Classifier
تابع زیان وزن‌دار	`BCEWithLogitsLoss (pos_weight = 1.7607)`	جبران عدم توازن کلاس‌های مثبت و منفی در افق‌های زمانی بالاتر
학습 بهینه‌ساز و کنترل	`AdamW (lr=1e-3, wd=1e-3) + GradClip(1.0)`	همراه با `ReduceLROnPlateau` و توقف زودهنگام (`Patience = 6`)

۵. روند آموزش و نتایج اعتبارسنجی

مدل تا سقف ۳۰ اپیاک تنظیم شد؛ در **اپیاک پنجم** به بهترین عملکرد (`mAP = 0.61823`) دست یافت و در اپیاک یازدهم با فعال شدن Early Stopping متوقف گردید:

اپیاک	زیان آموزش	زیان اعتبارسنجی	AP (0.5s)	AP (1.0s)	AP (1.5s)	میانگین AP (mAP)
`Epoch 1`	`0.84822`	`0.80997`	`0.7111`	`0.5365`	`0.4143`	`0.55397`
`Epoch 3`	`0.75591`	`0.79654`	`0.7534`	`0.6011`	`0.4806`	`0.61172`
`Epoch 5 (Best)`	`0.69857`	`0.76609`	`0.7541`	`0.6092`	`0.4914`	`0.61823`
`Epoch 9`	`0.54463`	`0.96628`	`0.7668`	`0.6067`	`0.4721`	`0.61519`
`Epoch 11 (Stop)`	`0.42174`	`1.16057`	`0.7165`	`0.5479`	`0.4459`	`0.57007`

گزارش نهایی بهترین چک‌پوینت (اپیاک ۵) به تفکیک افق زمانی

افق زمانی (Horizon)	دقت متوسط (AP)	معیار ROC-AUC	نرخ نمونه مثبت (Positive Rate)	تعداد نمونه‌ها
`0.5` ثانیه قبل از رویداد	`0.7541`	`0.7686`	`0.4700 (47.0%)`	`300`
`1.0` ثانیه قبل از رویداد	`0.6092`	`0.7436`	`0.3467 (34.7%)`	`300`
`1.5` ثانیه قبل از رویداد	`0.4914`	`0.7629`	`0.2267 (22.7%)`	`300`

۶. استنتاج روی داده تست و جمع‌بندی نهایی

از آنجا که ویدیوهای تست حدود ۱۰ ثانیه طول دارند و دقیقاً در یکی از افق‌های پیش‌بینی پنهان خاتمه می‌یابند، **۱۰ ثانیه پایانی هر ویدیوی تست** به عنوان یک کلیپ واحد (۱,۳۴۴ کلیپ با شکل ویژگی **`(1344, 24, 512)`**) استخراج و توسط مدل ارزیابی شد. احتمالات نهایی تولیدشده در فایل **`submission.csv`** در بازه **`[0.011073, 0.854871]`** قرار دارند.

> **مزیت کلیدی رویکرد دوم:** این معماری با جداسازی مرحله استخراج ویژگی (ResNet18) از مدل‌سازی دنباله (Bi-GRU + Attention) و حفظ نسبت تصویر ۱۶:۹ (**`128×224`** با ۲۴ فریم)، در افق زمانی نزدیک (۰.۵ ثانیه) به دقت بسیار بالای **AP = `0.7541`** و **ROC-AUC = `0.7686`** دست می‌یابد و امکان آزمایش سریع معماری‌های دنباله‌ای را فراهم می‌سازد.